

Análise Discriminante em Detecção de Risco de Crédito

Emanuel Franklin Passos Simões - 23.2.4009

Introdução

A análise discriminante consiste em técnicas estatísticas que combinam duas ou mais variáveis em grupos definidos previamente, com o objetivo de classificar as variáveis a partir de pesos que maximizam a diferença entre os grupos (Joseph et al., 2009, p. 224).

Diante disso, o presente trabalho consiste na realização de uma análise discriminante para fazer uma análise de risco de uma instituição financeira, para identificar clientes com alto risco de inadimplência, com o objetivo de desenvolver um sistema de classificação.

Materiais e métodos

A base de dados [dados_risco.csv](#) possui 550 observações, de modo que cada uma corresponde a um cliente, e 7 variáveis, que são:

- `valor_limite`: limite total de crédito disponível;
- `dias_atraso_medio`: média de dias de atraso nos últimos 12 meses;
- `qt_atrasos_12m`: número de atrasos registrados;
- `ratio_divida_renda`: razão dívida/renda mensal;
- `dist_agencia_resid`: distância entre residência e agência mais próxima;
- `mudancas_endereco_6m`: mudanças de endereço recentes;
- `classe`: população (Adimplente ou Risco).

Os métodos que serão aplicados são a análise exploratória e análise discriminante.

Resultados e discussão

Este tópico apresenta a análise descritiva dos dados, a aplicação da análise discriminante e uma breve discussão sobre cada análise.

```
## Instalação e importação de pacotes -----  
  
if (!requireNamespace("pacman", quietly = TRUE)) {  
  install.packages("pacman")  
}  
  
pacman::p_load(biotools, caret, corrplot, RColorBrewer, skimr, tidyverse)  
  
## Importação dos dados -----  
dados <- read.csv('tabelas/dados_risco.csv')  
dados$classe <- factor(dados$classe)  
head(dados)
```

	valor_limite	dias_atraso_medio	qt_atrasos_12m	ratio_divida_renda
1	39221.52	16.47	2	0.526
2	24065.86	3.96	1	0.386
3	20044.73	15.74	2	0.379
4	16215.40	22.58	1	0.607
5	12831.30	10.78	1	0.332
6	13485.17	6.38	0	0.323

	dist_agencia_resid	mudancas_endereco_6m	classe
1	10.31	0	Adimplente
2	9.48	1	Adimplente
3	31.14	2	Risco
4	7.37	0	Risco
5	7.83	0	Risco
6	6.05	0	Adimplente

Análise descritiva

O tópico abrange um resumo dos dados com análise da estrutura, as distribuições, boxplots, relações bivariadas e matrizes de correlação por grupo, acrescentado de breves discussões.

Visão geral

```
skim(dados)
```

Table 1: Data summary

Name	dados
Number of rows	550
Number of columns	7
Column type frequency:	
factor	1
numeric	6
Group variables	
None	

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
classe	0	1	FALSE	2	Adi: 385, Ris: 165

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
valor_limite	0	1	20174.49	9904.22	122.76	13003.35	18262.40	24484.06	61973.28	
dias_atraso_medio	0	1	9.95	7.18	0.42	4.94	8.11	12.76	46.04	
qt_atrasos_12m	0	1	0.69	0.91	0.00	0.00	0.00	1.00	7.00	
ratio_divida_renda	0	1	0.33	0.15	0.01	0.21	0.32	0.43	0.81	
dist_agencia_resid	0	1	12.46	7.02	0.66	7.40	11.06	16.07	42.04	
mudancas_endereco	0.6m	1	0.34	0.64	0.00	0.00	0.00	1.00	4.00	

A primeira vista, percebe-se que os dados possuem escalas diferentes. O valor limite, por tratar-se de valores financeiros altos, está em uma escala bem superior as demais. Essa informação é relevante para a análise, pois a análise depende da distância, portanto é crucial que os dados estejam na mesma escala. Ademais, não há valores ausentes na base de dados.


Observa-se que todas as distribuições, com exceção da **ratio_divida_renda**, possuem forte assimetria à direita. Isso sugere a possível existência de valores discrepantes. Como a análise

não exige normalidade nem comparação de médias, não será feita uma transformação de variáveis. Outro ponto é que não detectou-se variáveis com distribuições heterogêneas, o que pode ser um indício de ausência de agrupamentos ou presença de poucos agrupamentos.

Distribuições

```
dados_long <- dados %>%
  pivot_longer(~classe, names_to = "variavel", values_to = "valor")

ggplot(dados_long, aes(x = valor, fill = classe)) +
  geom_density(alpha = 0.5) +
  facet_wrap(~ variavel, scales = "free", ncol = 3) +
  theme_minimal(base_size = 13) +
  labs(title = "Distribuições das variáveis por população",
       x = "Valor", y = "Densidade")
```




Quanto aos dias de atraso médio mensal, mudanças de endereço recente, número de atrasos registrados, razão da dívida com a renda mensal, observa-se que os adimplentes possuem uma frequência percentual maior em poucos dias de atraso, enquanto clientes classificados como risco possuem frequência percentual maior em vários dias de atraso. O que significa que as variáveis parecem estar bem definidas, indo além da própria aleatoriedade. Isso favorece a tentativa de fazer uma análise discriminante para classificar novos clientes.

Verificou-se que a distância entre a agência e a residência do cliente é bastante semelhante nas duas classes, assim como o limite total de crédito disponível.

Boxplots


```
ggplot(dados_long, aes(x = classe, y = valor, fill = classe)) +
  geom_boxplot(alpha = 0.7, outlier.alpha = 0.3) +
  facet_wrap(~ variavel, scales = "free", ncol = 3) +
  theme_minimal(base_size = 13) +
  labs(title = "Boxplots comparativos entre Regular e Suspeito",
       x = "", y = "Valor")
```



A partir da análise dos boxplots, percebe-se que a classe adimplente possui medianas menores em todas as variáveis, com exceção da **valor_limite**. Portanto, há mais evidências de que a estrutura está bem definida.

Relações bivariadas

```
ggplot(dados, aes(x = ratio_divida_renda,
                  y = dias_atraso_medio,
                  color = classe)) +
  geom_point(alpha = 0.5) +
  stat_ellipse(type = "norm", linewidth = 1.1) +
  theme_minimal(base_size = 13) +
  labs(title = "Relação bivariada com elipses gaussianas",
       x = "Ratio divida/renda",
       y = "Dias atraso médio")
```




A partir da análise da relação bivariada entre as variáveis `ratio_divida_renda` e `dias_atraso_medio`, verificou-se a presença de duas populações com posições e dispersões diferentes. A classe `Risco` possui uma dispersão maior do que a classe `Adimplente`. Porém, como há uma grande região de sobreposição entre as variáveis, vale fazer uma análise multivariada para captar melhor a estrutura discriminante dos dados.

Projeção PCA das duas populações

```
X_scaled <- scale(dados[, -7])
pca <- prcomp(X_scaled)
```

```
pca_df <- data.frame(pca$x[,1:2], classe = dados$classe)

ggplot(pca_df, aes(PC1, PC2, color = classe)) +
  geom_point(alpha = 0.6) +
  stat_ellipse(type = "norm") +
  theme_minimal(base_size = 13) +
  labs(title = "Projeção PCA das duas populações",
       x = "PC1", y = "PC2")
```



A análise de componentes principais reforça a diferença entre as classes Adimplente e Risco, de modo que Risco possui uma variabilidade maior e centróide numa posição diferente da classe Adimplente. Porém, as classes ainda estão sobrepostas, portanto, vale partir para uma análise discriminante supervisionada para melhorar a capacidade de classificação.

Gráfico de cores com matriz de correlação


Adimplente

```
cor_adimplente <- dados %>%
  filter(classe == 'Adimplente') %>%
  dplyr::select(-classe) %>%
  cor()
```

```

corrplot(
  cor_adimplente,
  method = "color",
  addCoef.col = "black",
  tl.col = "black",
  tl.srt = 45
)

```




Risco

```

cor_risco <- dados %>%
  filter(classe == 'Risco') %>%
  dplyr::select(-classe) %>%
  cor()

corrplot(
  cor_risco,
  method = "color",
  addCoef.col = "black",
  tl.col = "black",
  tl.srt = 45
)

```

O gráfico de cores com matriz de covariância é uma ótima ferramenta para visualizar se há correlações entre variáveis e até estruturas latentes. Observou-se que a única correlação moderada é a de **ratio_divida_renda** e **dias_atraso_medio**, portanto é visível que pessoas que costumam atrasar o pagamento muitas vezes possuem uma dívida alta em comparação com a renda. As demais correlações são muito baixas para trazer uma interpretação.

Verificar suposições

Foi feito a aplicação do teste de Box (Box's M) e comparação das matrizes de covariância das populações.

Teste de Box

```
#H_0: Sigma_R = Sigma_S = Sigma

box_res <- biotools::boxM(dados[, -7], dados$classe)
box_res
```

Box's M-test for Homogeneity of Covariance Matrices

```
data: dados[, -7]
```

```
Chi-Sq (approx.) = 150.25, df = 21, p-value < 2.2e-16
```

Como p-valor é extremamente baixo, isso significa que há evidência de diferença entre as matrizes, o que significa que as populações possivelmente apresentam estruturas de variação distintas.

Comparação direta das covariâncias

```
cov_adimplente <- cov(dados[dados$classe == "Adimplente", -7])
cov_adimplente
```

	valor_limite	dias_atraso_medio	qt_atrasos_12m
valor_limite	9.856670e+07	5750.7431939	-36.246166193
dias_atraso_medio	5.750743e+03	34.6546954	0.186800731
qt_atrasos_12m	-3.624617e+01	0.1868007	0.479802489
ratio_divida_renda	2.618458e+02	0.2447302	0.002857589
dist_agencia_resid	2.268775e+03	3.7222984	-0.174929248
mudancas_endereco_6m	-7.808238e+01	0.3603599	-0.002962662

	ratio_divida_renda	dist_agencia_resid	mudancas_endereco_6m
valor_limite	2.618458e+02	2268.77514511	-78.082383523
dias_atraso_medio	2.447302e-01	3.72229840	0.360359916
qt_atrasos_12m	2.857589e-03	-0.17492925	-0.002962662
ratio_divida_renda	1.813525e-02	0.02364498	0.009293006
dist_agencia_resid	2.364498e-02	45.20412137	0.117931074
mudancas_endereco_6m	9.293006e-03	0.11793107	0.308685065

```
cov_risco <- cov(dados[dados$classe == "Risco", -7])
cov_risco
```

	valor_limite	dias_atraso_medio	qt_atrasos_12m
valor_limite	92117397.7504	9833.5118674	1507.18468182
dias_atraso_medio	9833.5119	78.3337808	3.03217517
qt_atrasos_12m	1507.1847	3.0321752	1.38115299
ratio_divida_renda	284.1644	0.6425512	0.04418525
dist_agencia_resid	6423.9295	16.9124367	2.37980931
mudancas_endereco_6m	-693.7291	0.4955299	-0.01807095

	ratio_divida_renda	dist_agencia_resid	mudancas_endereco_6m
valor_limite	284.1644	16.9124367	-0.01807095
dias_atraso_medio	0.6425512	2.37980931	0.4955299
qt_atrasos_12m	0.04418525	0.4955299	-0.01807095
ratio_divida_renda	1.38115299	0.4955299	-0.01807095
dist_agencia_resid	0.4955299	-0.01807095	0.4955299
mudancas_endereco_6m	-0.01807095	0.4955299	-0.01807095

valor_limite	2.841644e+02	6423.9295419	-6.937291e+02
dias_atraso_medio	6.425512e-01	16.9124367	4.955299e-01
qt_atrasos_12m	4.418525e-02	2.3798093	-1.807095e-02
ratio_divida_renda	1.995844e-02	0.1600317	1.283703e-03
dist_agencia_resid	1.600317e-01	57.6638003	4.875909e-01
mudancas_endereco_6m	1.283703e-03	0.4875909	5.862528e-01

`cov_risco - cov_adimplente`

	valor_limite	dias_atraso_medio	qt_atrasos_12m
valor_limite	-6.449298e+06	4082.768674	1543.43084801
dias_atraso_medio	4.082769e+03	43.679085	2.84537444
qt_atrasos_12m	1.543431e+03	2.845374	0.90135050
ratio_divida_renda	2.231861e+01	0.397821	0.04132767
dist_agencia_resid	4.155154e+03	13.190138	2.55473856
mudancas_endereco_6m	-6.156468e+02	0.135170	-0.01510829

	ratio_divida_renda	dist_agencia_resid	mudancas_endereco_6m
valor_limite	22.318605129	4155.1543968	-6.156468e+02
dias_atraso_medio	0.397820950	13.1901383	1.351700e-01
qt_atrasos_12m	0.041327666	2.5547386	-1.510829e-02
ratio_divida_renda	0.001823195	0.1363867	-8.009303e-03
dist_agencia_resid	0.136386730	12.4596789	3.696598e-01
mudancas_endereco_6m	-0.008009303	0.3696598	2.775677e-01

Observa-se que, com excessão da covariância da variável `valor_limite`, das variáveis `valor_limite` e `mudancas_endereco_6m`, das variáveis `mudancas_endereco_6m` e `qt_atrasos_12m` e das variáveis `mudancas_endereco_6m` e `ratio_divida_renda`, em todas as outras o valor da covariância da classe Risco é maior. Percebe-se que há evidência de que tanto o `valor_limite` quanto a `mudancas_endereco_6m` não são tão relevantes para avaliar o risco de inadimplência. Além disso, reparou-se que o fato da estrutura da classe Risco ter covariância predominantemente maior, reflete que a estrutura é mais dispersa e menos estável.

Ajuste dos modelos discriminantes

Será feito o ajuste a partir do método da ressubstituição, método divisão treino / teste (ressubstituição com divisão amostral) e Validação cruzada. Para todos os métodos será aplicado tanto a análise discriminante linear quanto a análise discriminante quadrática, bem como a avaliação de cada um.

Método da ressubstituição

Função discriminante linear (LDA)

```
X_scaled <- scale(dados[, -7])
df_scaled <- data.frame(classe = dados$classe, X_scaled)

fit_lda <- MASS::lda(classe ~ ., data = df_scaled)
fit_qda <- MASS::qda(classe ~ ., data = df_scaled)

fit_lda
```

Call:

```
lda(classe ~ ., data = df_scaled)
```

Prior probabilities of groups:

Adimplente	Risco
0.7	0.3

Group means:

	valor_limite	dias_atraso_medio	qt_atrasos_12m	ratio_divida_renda
Adimplente	0.08438768	-0.1790606	-0.2129440	-0.2598727
Risco	-0.19690459	0.4178081	0.4968694	0.6063696

	dist_agencia_resid	mudancas_endereco_6m
Adimplente	-0.06372002	-0.1583800
Risco	0.14868005	0.3695533

Coefficients of linear discriminants:

	LD1
valor_limite	-0.36831825
dias_atraso_medio	0.14112423
qt_atrasos_12m	0.50134099
ratio_divida_renda	0.69253918
dist_agencia_resid	0.05065587
mudancas_endereco_6m	0.34162707

Dado o desbalanceamento da proporção de dados classificados como Adimplentes e Risco, foi definido a probabilidade de 0.7 para o grupo de Adimplentes e 0.3 para o grupo de Risco.

Quanto às médias padronizadas, apenas a média da variável `valor_limite` da classe Risco é inferior a da classe Adimplente. Isso implica que a classe Risco há maior exposição.

Quanto aos coeficientes da função discriminante (LD1), percebe-se que os das variáveis `ratio_divida_renda` e `qt_atrasos_12m` possuem maior contribuição na separação dos grupos, enquanto as demais possuem contribuição menor, com exceção da variável `valor_limite`, que possui contribuição negativa.


Portanto, a razão dívida / renda mensal e a quantidade de atrasos registrados nos últimos 12 meses são as características principais para analisar a separação dos dois grupos, conforme a função discriminante linear do método da ressubstituição.

```
# Obter projeções LD1
lda_proj <- predict(fit_lda)$x

dados_plot <- dados %>%
  mutate(LD1 = lda_proj[,1])

# -----
# Gráfico das densidades na direção discriminante
# -----
ggplot(dados_plot, aes(x = LD1, fill = classe, color = classe)) +
  geom_density(alpha = 0.35, linewidth = 1.2) +
  geom_vline(
    data = dados_plot %>%
      group_by(classe) %>%
      summarise(m = mean(LD1)),
    aes(xintercept = m, color = classe),
    linetype = "dashed",
    linewidth = 1.1
  ) +
  labs(
    title = "Projeção na Função Discriminante Linear (LD1)",
    x = "Score discriminante (LD1)",
    y = "Densidade"
  ) +
  theme_minimal(base_size = 14) +
  theme(
    plot.title = element_text(face = "bold"),
    legend.position = "top"
  )
```

Projeção na Função Discriminante Linear (L



Diante desse gráfico da densidade de LD1, percebe-se a diferença entre as classes Adimplente e Risco, de modo que a classe Adimplente se concentra nos valores menores, enquanto a classe Risco se distribui nos valores maiores. Observa-se também que mesmo que há sobreposição, por terem a média bem separada, as classes possuem um bom poder discriminante.

Avaliação do modelo linear

```
pred_lda_resub <- predict(fit_lda)$class  
  
conf_lda_resub <- confusionMatrix(pred_lda_resub, factor(dados$classe), positive = 'Risco')  
conf_lda_resub
```

Confusion Matrix and Statistics

	Reference	
Prediction	Adimplente	Risco
Adimplente	358	90
Risco	27	75

Accuracy : 0.7873
95% CI : (0.7507, 0.8208)
No Information Rate : 0.7
P-Value [Acc > NIR] : 2.571e-06

```

Kappa : 0.4315

McNemar's Test P-Value : 9.931e-09

Sensitivity : 0.4545
Specificity : 0.9299
Pos Pred Value : 0.7353
Neg Pred Value : 0.7991
Prevalence : 0.3000
Detection Rate : 0.1364
Detection Prevalence : 0.1855
Balanced Accuracy : 0.6922

'Positive' Class : Risco

```

A acurácia da função discriminante linear obtida foi de 78,73%, com um p-valor < 0.001 , ou seja, estatisticamente significativo. Também percebe-se elevada especificidade (0.9299), indicando que o modelo é bom em detectar corretamente os clientes da classe Adimplente. Já a sensibilidade é moderada (0.4545), o que indica maior dificuldade em detectar os casos da classe Risco. O valor Kappa obtido foi de 0.4315, o que indica concordância moderada entre as predições e as classes reais. Já a acurácia balanceada (0.6922) indica que o desempenho não é uniforme entre as classes. No geral, o modelo possui bom desempenho, mas necessita de ajustes dependendo das prioridades.

Função discriminante quadrática (QDA)

```
fit_qda
```

Call:

```
qda(classe ~ ., data = df_scaled)
```

Prior probabilities of groups:

Adimplente	Risco
0.7	0.3

Group means:

	valor_limite	dias_atraso_medio	qt_atrasos_12m	ratio_divida_renda
Adimplente	0.08438768	-0.1790606	-0.2129440	-0.2598727
Risco	-0.19690459	0.4178081	0.4968694	0.6063696

	dist_agencia_resid	mudancas_endereco_6m
Adimplente	-0.06372002	-0.1583800
Risco	0.14868005	0.3695533

x

```
pred_qda_resub <- predict(fit_qda)$class

conf_qda_resub <- confusionMatrix(pred_qda_resub, factor(dados$classe), positive = 'Risco')
conf_qda_resub
```

Confusion Matrix and Statistics

	Reference	
Prediction	Adimplente	Risco
Adimplente	346	88
Risco	39	77

Accuracy : 0.7691
 95% CI : (0.7316, 0.8037)
 No Information Rate : 0.7
 P-Value [Acc > NIR] : 0.0001786

Kappa : 0.3992

McNemar's Test P-Value : 2.051e-05

Sensitivity : 0.4667
 Specificity : 0.8987
 Pos Pred Value : 0.6638
 Neg Pred Value : 0.7972
 Prevalence : 0.3000
 Detection Rate : 0.1400
 Detection Prevalence : 0.2109
 Balanced Accuracy : 0.6827

'Positive' Class : Risco

Em comparação com a função discriminante linear, o quadrático foi melhor apenas na sensibilidade (0.4667 de 0.4545).

Divisão treino / teste

```
set.seed(12345)

train_id <- createDataPartition(dados$classe, p = 0.7, list = FALSE)

train <- dados[train_id, ]
test  <- dados[-train_id, ]
```

Em conformidade com as probabilidades definidas anteriormente, estabeleceu-se 70% dos dados para treino e 30% para teste.

```
prop.table(table(dados$classe))
```

Adimplente	Risco
0.7	0.3

```
prop.table(table(train$classe))
```

Adimplente	Risco
0.6994819	0.3005181

```
prop.table(table(test$classe))
```

Adimplente	Risco
0.7012195	0.2987805

```
preproc <- preProcess(train[, -7], method = c("center", "scale"))

train_scaled <- predict(preproc, train)
test_scaled  <- predict(preproc, test)
```

```
fit_lda <- lda(classe ~ ., data = train_scaled)

fit_lda
```

```
Call:
lda(classe ~ ., data = train_scaled)
```

Prior probabilities of groups:

```
Adimplente      Risco
0.6994819 0.3005181
```

Group means:

```
      valor_limite dias_atraso_medio qt_atrasos_12m ratio_divida_renda
Adimplente  0.0955675      -0.1521279      -0.2149208      -0.2142875
Risco      -0.2224416      0.3540909      0.5002468      0.4987726
      dist_agencia_resid mudancas_endereco_6m
Adimplente  -0.06762802      -0.1359754
Risco        0.15741005      0.3164944
```

Coefficients of linear discriminants:

```
      LD1
valor_limite      -0.41163014
dias_atraso_medio  0.10909157
qt_atrasos_12m     0.60613082
ratio_divida_renda 0.59322673
dist_agencia_resid 0.08724126
mudancas_endereco_6m 0.29188612
```

Função discriminante linear (LDA)

```
pred_lda_test <- predict(fit_lda, newdata = test_scaled)$class

conf_lda_test <- confusionMatrix(pred_lda_test,
                                  factor(test_scaled$classe),
                                  positive = "Risco")

conf_lda_test
```

Confusion Matrix and Statistics

```
      Reference
Prediction Adimplente Risco
Adimplente      111      24
Risco              4      25
```

Accuracy : 0.8293

95% CI : (0.7628, 0.8835)
No Information Rate : 0.7012
P-Value [Acc > NIR] : 0.0001218

Kappa : 0.5385

McNemar's Test P-Value : 0.0003298

Sensitivity : 0.5102
Specificity : 0.9652
Pos Pred Value : 0.8621
Neg Pred Value : 0.8222
Prevalence : 0.2988
Detection Rate : 0.1524
Detection Prevalence : 0.1768
Balanced Accuracy : 0.7377

'Positive' Class : Risco

Já nesse caso, obteve-se valores tanto de Acurácia, Kappa, sensibilidade e especificidade superiores aos anteriores.

Função discriminante quadrática (QDA)

```
fit_qda <- qda(classe ~ ., data = train_scaled)
fit_qda
```

Call:

```
qda(classe ~ ., data = train_scaled)
```

Prior probabilities of groups:

Adimplente	Risco
0.6994819	0.3005181

Group means:

	valor_limite	dias_atraso_medio	qt_atrasos_12m	ratio_divida_renda
Adimplente	0.0955675	-0.1521279	-0.2149208	-0.2142875
Risco	-0.2224416	0.3540909	0.5002468	0.4987726

	dist_agencia_resid	mudancas_endereco_6m
Adimplente	-0.06762802	-0.1359754
Risco	0.15741005	0.3164944

Avaliação do modelo quadrático

```
pred_qda_test <- predict(fit_qda, newdata = test_scaled)$class

conf_qda_test <- confusionMatrix(pred_qda_test,
                                  factor(test_scaled$classe),
                                  positive = "Risco")

conf_qda_test
```

Confusion Matrix and Statistics

	Reference	
Prediction	Adimplente	Risco
Adimplente	103	24
Risco	12	25

Accuracy : 0.7805
95% CI : (0.7093, 0.8413)
No Information Rate : 0.7012
P-Value [Acc > NIR] : 0.01460

Kappa : 0.4365

McNemar's Test P-Value : 0.06675

Sensitivity : 0.5102
Specificity : 0.8957
Pos Pred Value : 0.6757
Neg Pred Value : 0.8110
Prevalence : 0.2988
Detection Rate : 0.1524
Detection Prevalence : 0.2256
Balanced Accuracy : 0.7029

'Positive' Class : Risco

Nesse caso, obteve-se desempenho inferior ao anterior.

Validação cruzada

Função discriminante linear (LDA)

```
train_control <- trainControl(method = "cv", number = 10)

lda_cv <- train(classe ~ ., data = train_scaled, method = "lda", trControl = train_control)

lda_cv$finalModel
```

Call:

```
lda(x, grouping = y)
```

Prior probabilities of groups:

Adimplente	Risco
0.6994819	0.3005181

Group means:

	valor_limite	dias_atraso_medio	qt_atrasos_12m	ratio_divida_renda
Adimplente	0.0955675	-0.1521279	-0.2149208	-0.2142875
Risco	-0.2224416	0.3540909	0.5002468	0.4987726

	dist_agencia_resid	mudancas_endereco_6m
Adimplente	-0.06762802	-0.1359754
Risco	0.15741005	0.3164944

Coefficients of linear discriminants:

	LD1
valor_limite	-0.41163014
dias_atraso_medio	0.10909157
qt_atrasos_12m	0.60613082
ratio_divida_renda	0.59322673
dist_agencia_resid	0.08724126
mudancas_endereco_6m	0.29188612

Avaliação do modelo linear

```
lda_cv$results
```

	parameter	Accuracy	Kappa	AccuracySD	KappaSD
1	none	0.7672065	0.3700933	0.09096502	0.2524665

A avaliação do modelo linear para o caso da validação cruzada apresentou resultados inferiores aos demais.

Função discriminante quadrática (QDA)

```
qda_cv <- train(classe ~ ., data = train_scaled, method = "qda", trControl = train_control)

qda_cv$finalModel
```

Call:

```
qda(x, grouping = y)
```

Prior probabilities of groups:

	Adimplente	Risco
	0.6994819	0.3005181

Group means:

	valor_limite	dias_atraso_medio	qt_atrasos_12m	ratio_divida_renda
Adimplente	0.0955675	-0.1521279	-0.2149208	-0.2142875
Risco	-0.2224416	0.3540909	0.5002468	0.4987726

	dist_agencia_resid	mudancas_endereco_6m
Adimplente	-0.06762802	-0.1359754
Risco	0.15741005	0.3164944

Avaliação do modelo quadrático

```
qda_cv$results
```

	parameter	Accuracy	Kappa	AccuracySD	KappaSD
1	none	0.7331984	0.2999838	0.03436691	0.09367579

Nesse caso, obteve-se um desempenho inferior aos demais.

Conclusões

Percebeu-se a importância da análise exploratória para buscar evidências de que a análise proposta faz sentido. Essa percepção foge à análise descritiva simples, pois exige investigação e interpretação, que são habilidades super necessárias para um analista de dados competente.

Quanto à análise discriminante, observou-se que o modelo linear teve resultados melhores do que o quadrático, em especial na divisão treino / teste.

Referências bibliográficas

HAIR, Joseph F. et al. **Análise multivariada de dados**. Bookman editora, 2009.